基于机器学习技术的盾构隧道掘进方向控制引导系统

和田健介[1], 杉山博一[1], 野泽孝次郎[1], 本田诚[1], and 山本真也[1]

[1] 清水建设株式会社，日本东京都江东区越中岛 3-4-17
[*] 通讯作者邮箱：wada@shimz.co.jp

摘要

为使盾构机沿设计线路掘进，对盾构千斤顶进行精准控制至关重要，而控制方案的制定取决于盾构机的实时位置与地质条件。但盾构机的方向控制效果，高度依赖操作人员的技能水平。基于此，本文研发了一套引导系统，其可提供与熟练操作人员技术水平相当的盾构千斤顶控制方法。该系统以熟练操作人员的操作相关数据为基础，采用梯度树提升算法训练机器学习模型，通过模型预测盾构千斤顶合力的最优作用点，从而实现对盾构机推进方向的控制。为验证引导系统的性能，在某在建工程中采用该系统指导盾构机掘进，结果表明，盾构机的线路偏差与姿态均控制在设定的容许偏差范围内。研究证实，该引导系统具备实际工程环境的适用性，为未来盾构机自动驾驶技术的实现提供了可能。

关键词： 盾构机；引导系统；机器学习

1 引言

在日本，少子老龄化问题持续加剧，建筑行业从业人员数量不断减少，熟练技术工人的雇佣难度日益增加。因此，行业内亟需实现施工的少人化，并为无经验操作人员提供技术辅助。

盾构隧道的施工质量，高度依赖盾构机操作人员的技能水平，这是因为盾构机的操作方案很大程度上由操作人员自主决定。熟练操作人员的短缺，将直接导致盾构隧道的施工质量下降。自动驾驶盾构机是保障盾构隧道施工质量的有效手段，但目前其研发仍面临诸多挑战。例如，已有研究采用模糊模型，实现了排土用螺旋输送机与推进用盾构千斤顶的自动化操作 [1]；也有研究通过监测数据估算土体物理性质，计算掘进所需力矩，从而自动选择需启用的盾构千斤顶 [2]。但上述方法均未能实现盾构机的全自动化，核心原因在于不同场地的地层条件与施工环境存在显著差异，难以精准预测盾构机的合理操作方案。

近年来，机器学习技术受到广泛关注，基于该技术可便捷地构建高性能模型。若将机器学习技术应用于盾构掘进的监测数据，有望实现盾构机的自动驾驶。已有研究表明，利用机器学习可构建具备与操作人员同等决策能力的模型 [3, 4, 5, 6]，这类模型可预测螺旋输送机的最优转速，以及用于控制盾构机推进方向的千斤顶合力最优作用点。作为实现盾构机自动驾驶的第一步，本团队此前已提出一种基于机器学习技术的盾构隧道掘进方向控制引导系统 [7]。

本研究对所提引导系统的工程适用性开展了系统分析。为验证系统的可行性，首先采用某已建盾构隧道的实测数据，对引导系统所用的机器学习模型进行训练，并评估了模型的预测精度。在确认模型输出与专家操作水平相当后，在另一在建盾构工程中，采用该引导系统指导盾构机掘进，最终通过分析盾构机的线路偏差与姿态控制效果，验证了引导系统的实际性能。

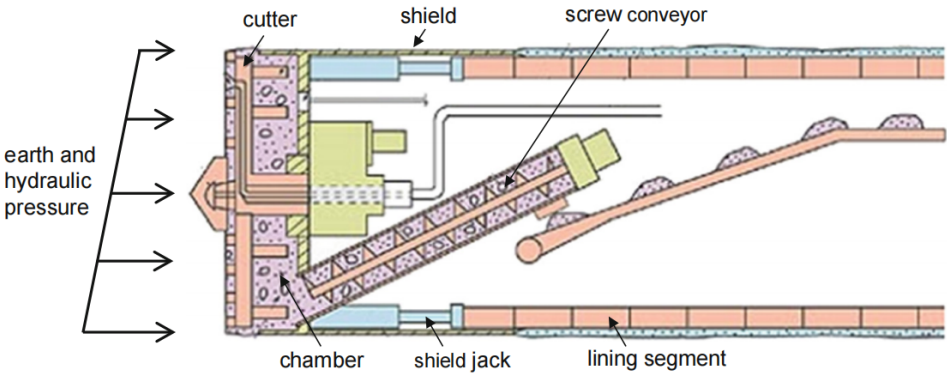

图 1. 盾构工法示意图

2 盾构工法

2.1 工法概述

盾构工法是在盾构结构支护周边地层的同时完成隧道修建的施工方法，其通过土仓内的土体或泥浆平衡地层土压力与水压力，从而维持开挖面的稳定。由于该工法可有效控制地层变形，因此广泛应用于软土地层的隧道施工。

盾构工法的施工流程如下：采用刀盘开挖与掌子面接触的地层；通过螺旋输送机排出土仓内的弃土；借助沿盾构环向布置的盾构千斤顶推动盾构机向前掘进；同步拼装衬砌管片。

2.2 盾构机的操作

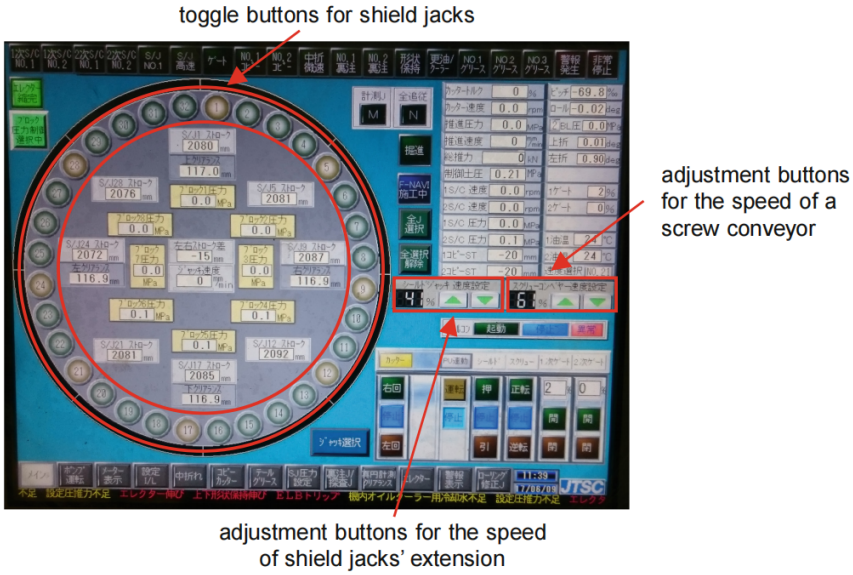

图 2. 盾构机操作界面示例

盾构机操作人员的操作主要分为三类：控制盾构机的推进方向、使土仓压力与地层压力相平衡、向土仓内注入添加剂及向盾尾空隙注入填充材料。操作人员需实时对比盾构机传感器采集的运行数据与设计值，同步完成盾构机的操作控制。设计值包括盾构机的方位角、俯仰角、盾构千斤顶行程伸长量等。要使

盾构机的所有控制指标均匹配设计值难度极高，因此对操作人员的技能水平提出了严苛要求。

控制盾构机的推进方向，是保障盾构隧道精准施工的核心任务。当操作人员仅启用部分盾构千斤顶时，作用于盾构机的推力会出现偏心，进而驱动盾构机转向，使其沿设计线路掘进。

3 盾构隧道掘进方向控制引导系统

3.1 引导系统概述

所研发的引导系统可给出盾构千斤顶的最优控制方案，保障盾构机沿设计线路掘进。图3为引导系统的执行流程，具体步骤如下：第一步，由管理人员输入当日掘进所需的设计参数；盾构机启动掘进后，引导系统实时采集盾构机的运行数据，计算特征变量；随后通过机器学习模型，基于特征变量预测是否需要进行盾构千斤顶操作；当判定需要操作时，系统采用其他机器学习模型，预测用于控制盾构推进方向的千斤顶合力最优作用点；最终基于预测的合力作用点筛选出需启用的盾构千斤顶，并将操作方案展示给操作人员，如图4所示。

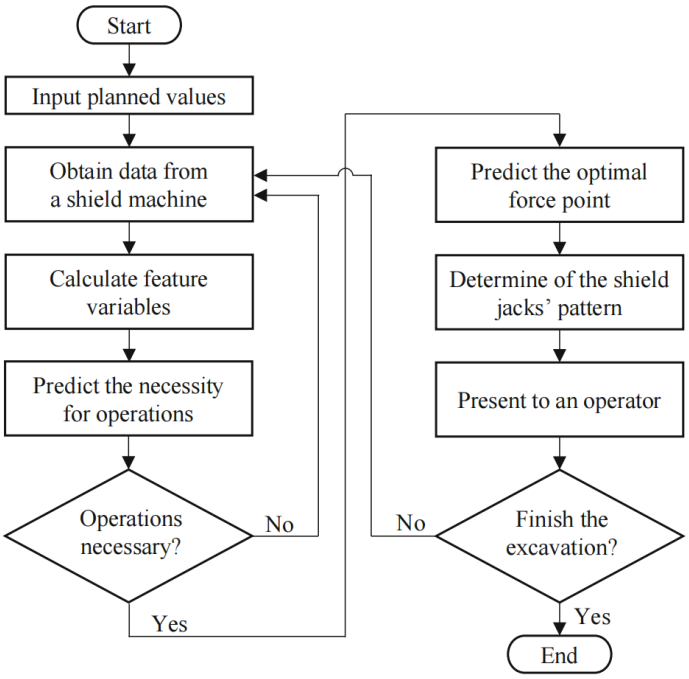

图 3. 引导系统执行流程

3.2 梯度提升决策树

梯度提升法是集成学习方法的一种，其核心是通过组合多个弱学习器构建强学习器。当采用决策树作为弱学习器时，该方法被称为梯度提升决策树（Gradient Boosting Decision Tree, GBDT）。

GBDT 通过以下迭代过程构建强学习器：初始强学习器 $F_0(x)$ 定义为：

$$F_0(x) = f_0(x) \tag{1}$$

式中：x 为特征变量向量；$f_0(x)$ 为基于决策树构建的弱学习器。

$F_0(x)$ 的均方根误差 E_0 计算公式为：

$$E_0 = \sqrt{(y - F_0(x))^2} \tag{2}$$

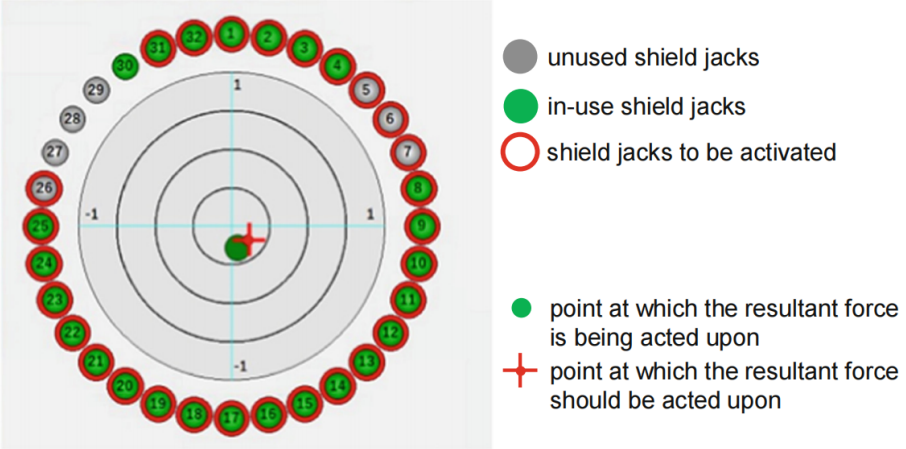

图 4. 向操作人员展示的引导界面示例

式中：y 为目标值向量。

以 E_0 为目标值构建弱学习器 $f_1(x)$，并将其与原有强学习器结合，得到：

$$F_1(x) = f_0(x) + f_1(x) \tag{3}$$

重复该过程 M 次后，可得到最终的强学习器：

$$F_M(x) = f_0(x) + f_1(x) + \cdots + f_M(x) \tag{4}$$

GBDT 通过迭代叠加弱学习器以持续降低预测误差，可构建出高性能的学习器。本研究采用开源 GBDT 算法库 XGBoost[10] 构建机器学习模型。

3.3 机器学习模型的数据集

表1列出了引导系统所用 3 个机器学习模型的输入与输出变量。其中一个模型以 Fc 为目标变量，预测盾构千斤顶操作的必要性（下文简称 Fc 模型）：当操作人员调整了启用的盾构千斤顶时，Fc 取值为 1；未调整时，Fc 取值为 0。另外两个模型分别以 Fx 和 Fy 为目标变量，预测盾构千斤顶合力作用点的水平与竖向坐标（下文简称 Fx 模型与 Fy 模型），其中 Fx 和 Fy 由各盾构千斤顶的实时推力计算得到。

除 Fc、Fx、Fy 外，其余变量均为操作人员控制盾构机时参考的监测数据，涵盖盾构机的运行状态参数、实测值与设计值的偏差量两大类。此外，考虑到操作人员会重点关注参数的时变特性，本研究将 1-10 s、11-20 s、21-30 s、31-60 s 区间内各参数的移动平均值，一并纳入特征变量中。

3.4 盾构千斤顶操作必要性的预测

Fc 模型用于预测盾构千斤顶的操作必要性，核心目的是避免过度操作。仅当距离引导系统上一次给出操作指令已达到预设等待时间，且 Fc 模型的输出值超过设定阈值时，系统才判定需要进行千斤顶操作。本研究中将等待时间设为 2 min，该时长足以使千斤顶操作的效果充分反映在盾构机的运行状态中。

由于操作人员通常每隔数十秒至数百秒才会调整一次盾构千斤顶，因此 Fc 的取值绝大多数为 0。若直接以原始 Fc 数据为目标变量训练模型，Fc 模型的输出值将几乎全部为 0，无法实现有效预测。为此，本研究采用加权数据对 Fc 模型进行训练。

预测千斤顶操作必要性时，需设定合理的分类阈值。图5为 Fc 模型预测值的概率分布示意图，当阈值确定后，可计算真阴性（TN）、假阴性（FN）、真阳性（TP）、假阳性（FP）的样本数量。本研究以

表 1. 机器学习模型所用数据集

变量	单位	目标变量	设备状态参数	与设计值的偏差
操作人员操作的二值化数据（Fc）	—	✓		
合力作用点水平坐标（Fx）	—	✓		
合力作用点竖向坐标（Fy）	—	✓		
扭矩（To）	%		✓	
掘进速度（Ve）	mm/min		✓	
总推力（Tr）	kN		✓	
掌子面压力（Fp）	MPa		✓	
俯仰角（Pt）	deg		✓	
滚转角（Ro）	deg		✓	
盾构千斤顶行程伸长量左右差与设计值的偏差（Dj）	mm			✓
方位角与设计值的偏差（Dd）	deg			✓
俯仰角与设计值的偏差（Dp）	deg			✓
线路水平偏差（Dh）	mm			✓
线路竖向偏差（Dv）	mm			✓

最小化平衡错误率（Balanced Error Rate, BER）为目标设定阈值，平衡错误率的计算公式为：

$$BER = 0.5 \times \left(\frac{FP}{TN + FP} + \frac{FN}{FN + TP} \right) \tag{5}$$

当 Fc 模型的输出值大于该阈值时，系统判定需要进行盾构千斤顶操作。

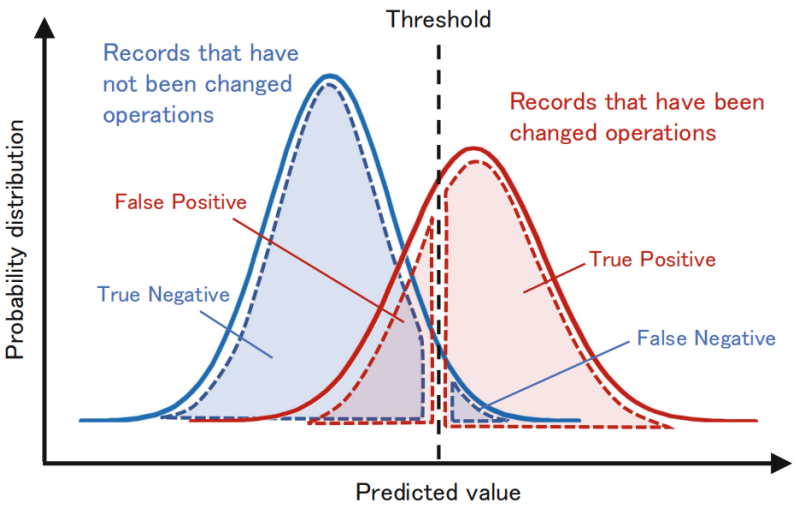

图 5. Fc 模型预测值的概率分布示意图

3.5 最优合力作用点的预测

Fx 模型与 Fy 模型用于预测盾构千斤顶合力的最优作用点。当系统判定需要进行操作时，两个模型将分别输出合力作用点的水平与竖向坐标。

Fx 模型与 Fy 模型，采用图5中被划分为 TP 和 FN 类别的数据进行训练。仅采用判定为需要操作的特征数据进行训练，能够构建出预测精度更高的模型。

3.6 盾构千斤顶启用方案的确定

引导系统给出的千斤顶操作方案，需避免对衬砌管片施加过大压力。为此，系统从过往专家选定的千斤顶启用方案中，筛选最终向操作人员展示的方案。具体方法为：系统将机器学习模型预测的合力作用点，与专家选定方案的合力作用点进行对比，最终选取二者空间距离最短的千斤顶启用方案进行展示。

4 结果与分析

4.1 机器学习模型的可行性验证

4.1.1 试验工点

为验证机器学习模型的可行性，本研究采用某已建盾构隧道的实测数据，对模型性能进行评估。图6为该试验工点示意图，该工程为高速公路匝道隧道，全长 448 m，包含 5.9% 7.6% 的下坡段，以及半径 50 m 的急曲线段，施工采用的盾构机直径为 10.8 m。

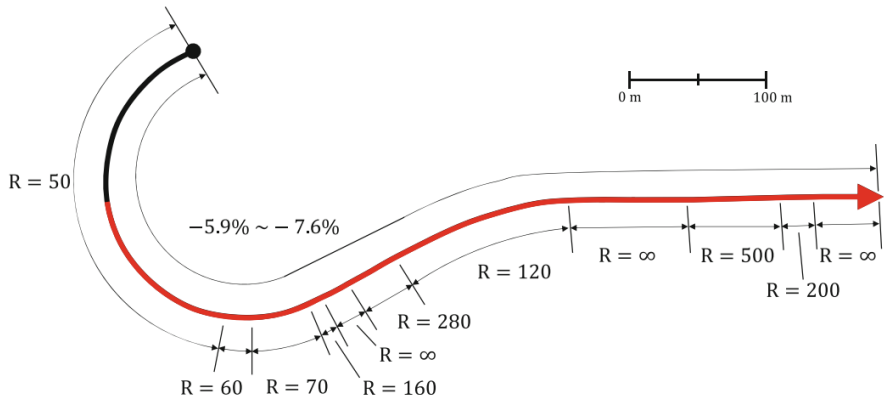

图 6. 机器学习模型可行性验证的目标盾构隧道

本研究采用图6中红线标注段采集的、时间间隔为 10 s 的数据集，对机器学习模型进行训练与性能评估。数据集总样本量约 14 万条，其中约 70% 用于模型训练，剩余数据用于模型性能评估；数据集按衬砌管片环为单位进行随机划分。

4.1.2 模型性能分析

图7为模型预测值（纵轴）与操作人员实际操作值（横轴）的对比结果，图中仅绘制了 Fc 模型判定为需要进行千斤顶操作的样本数据。结果显示，图7(a)（Fx）的相关系数为 0.749，图7(b)（Fy）的相关系数为 0.730，二者均呈现显著的正相关关系。但在 Fx 取值远离原点的区域，Fx 模型的预测精度出现明显下降。

为检验模型精度的衰减规律，本研究绘制了提升图，如图8所示。绘制方法为：将预测值按降序排列后，将数据集划分为 60 个数据块，图中绘制了每个数据块的平均值。统计结果表明，Fx 在-0.2 0.2 区间内的平均误差为 0.0199，而该区间外的平均误差为 0.0889，说明当 Fx 超出-0.2 0.2 区间时，Fx 模型的性能会显著下降。而 Fy 模型在全区间内均保持了良好的预测性能。

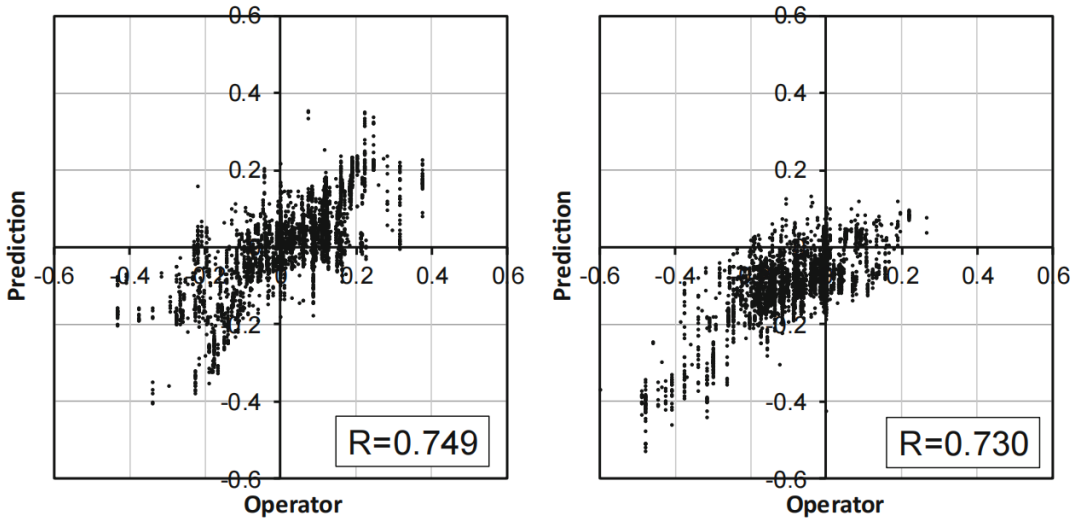

(a) *Fx* (b) *Fy*

图 7. 模型预测值与操作人员实际操作值的对比结果

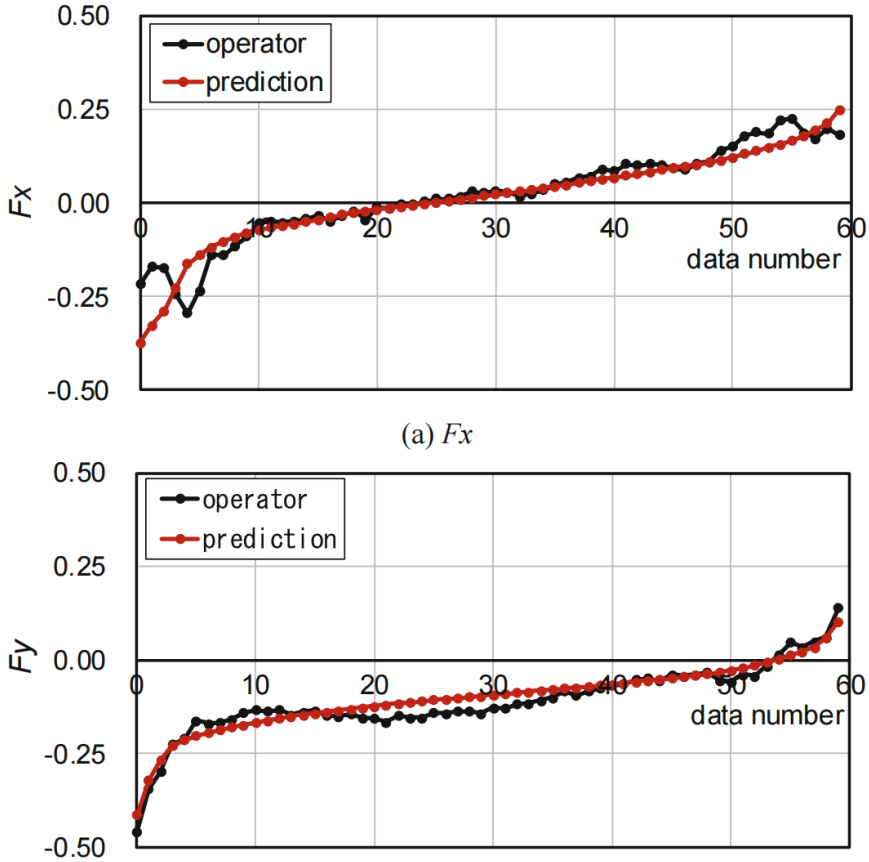

(a) *Fx*

(b) *Fy*

图 8. 模型预测值与实际操作值的提升图

为验证模型在 Fx 和 Fy 不同取值区间内的预测效果，本研究绘制了盾构千斤顶合力作用点的轨迹图，如图9所示。其中 (a) (d) 分别展示了合力作用点位于四个象限的单环管片掘进过程的轨迹。结果显示，尽管预测点的变动频率高于实际操作记录，但二者的整体差异并不显著。

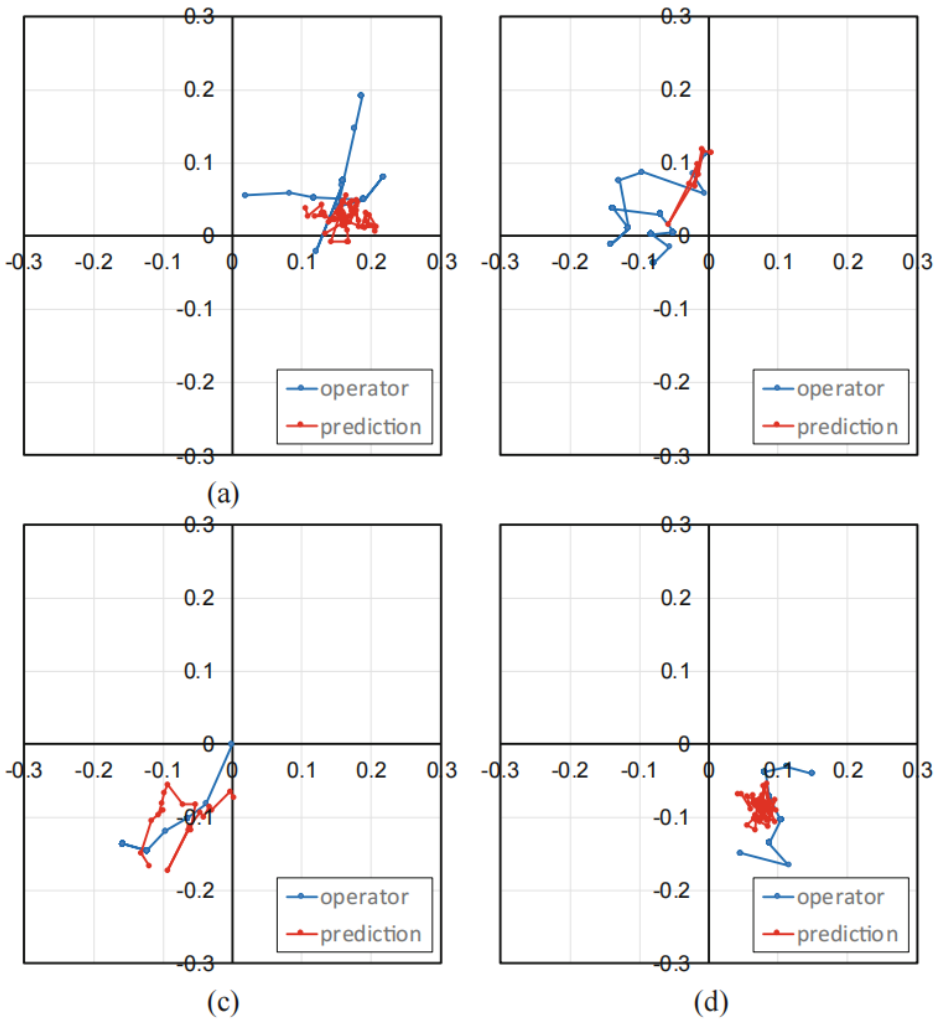

图 9. 盾构千斤顶合力作用点轨迹

图10为各特征变量对 Fx 模型与 Fy 模型的影响率。特征变量的影响率计算方法为：将原始数据中某一特征变量的数值随机打乱，用模型对处理后的数据进行预测，根据模型精度的衰减程度计算得到该变量的影响率。特征变量的影响率越大，代表打乱该变量后模型精度的衰减越严重；当模型精度衰减程度最大时，影响率取值为 1。

结果表明，水平线路偏差 Dh 与方位角偏差 Dd 对 Fx 模型的影响最为显著，俯仰角偏差 Dp 与竖向线路偏差 Dv 对 Fy 模型的影响最大。这一结果与操作人员控制过程中重点关注的参数完全一致，说明模型能够做出符合工程逻辑的合理预测。

上述结果表明，当 Fx 处于-0.2 0.2 区间内时，模型能够精准预测盾构千斤顶的合力作用点。Fx 模型在该区间外的精度下降，主要由训练数据不足导致，可通过采集更多工况的数据解决这一问题。此外，在实际工程操作中，操作人员极少将 Fx 设置在-0.2 0.2 区间之外。综上，采用机器学习技术能够构建适用于实际工程环境的预测模型。

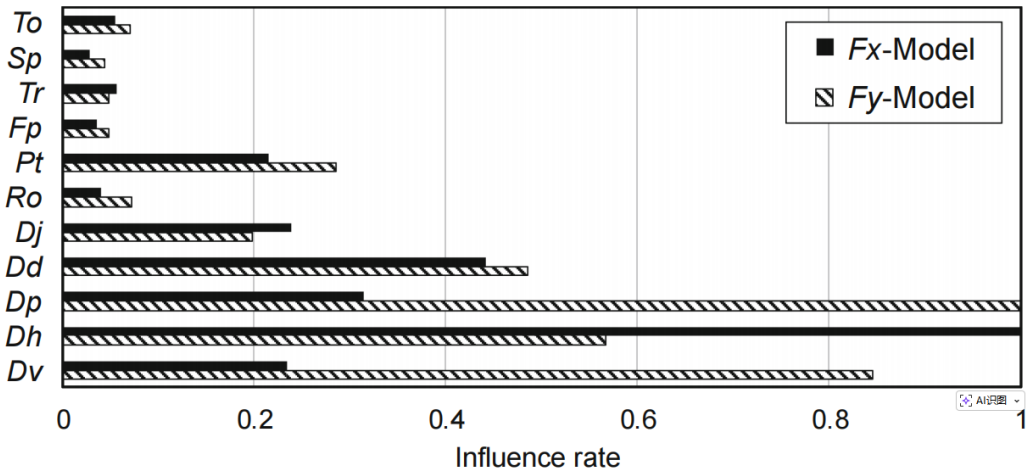

图 10. 各特征变量对 Fx 模型与 Fy 模型的影响率

4.2 引导系统的工程适用性验证

4.2.1 试验工点

为验证引导系统在实际工程中的性能，本研究在某在建盾构隧道中，采用该系统指导盾构机掘进。图11为该试验工点示意图，隧道全长 1845 m，包含-5.0% 5.0% 的坡度段，以及半径 220 m 的曲线段，施工采用的盾构机直径为 11.9 m。

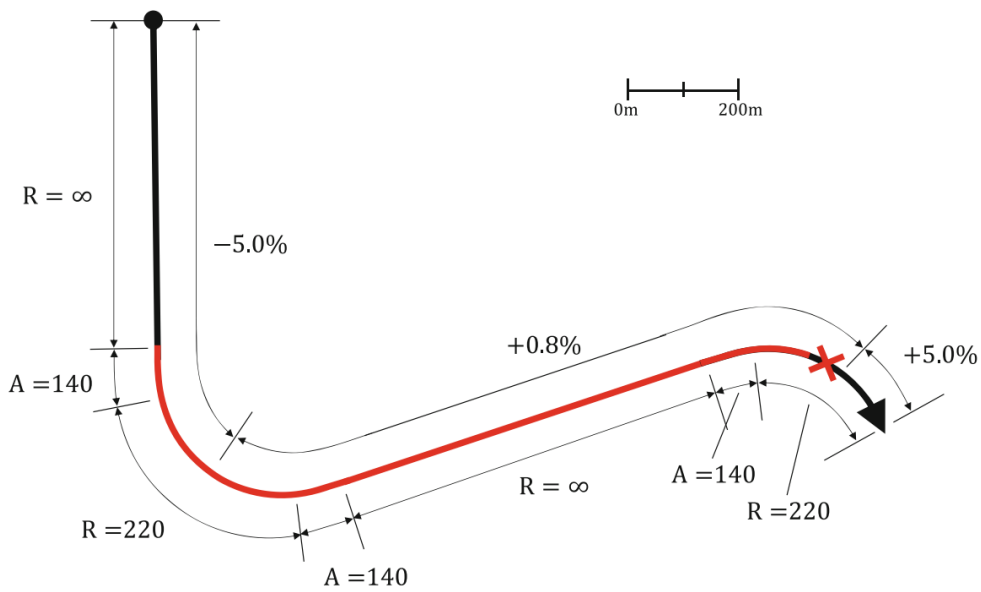

图 11. 引导系统性能验证的目标盾构隧道

本研究采用图11中红线标注段采集的、时间间隔为 1 s 的数据集对模型进行训练，总样本量约 120 万条；同时，在图11中标记的试验区段，对引导系统的实际性能进行了评估。

4.2.2 引导系统性能分析

图12为盾构千斤顶合力作用点的时程变化曲线，其中黑色虚线为操作人员的实际操作值，红色实线为引导系统的输出值。掘进初期系统未输出指令，原因在于需要采集一定量的基础数据后，才能计算输入模型的特征变量移动平均值。对比实际操作记录与系统输出值可以发现，尽管二者存在少量差异，但操作人员总体上严格按照引导系统的指令完成了盾构千斤顶的控制。

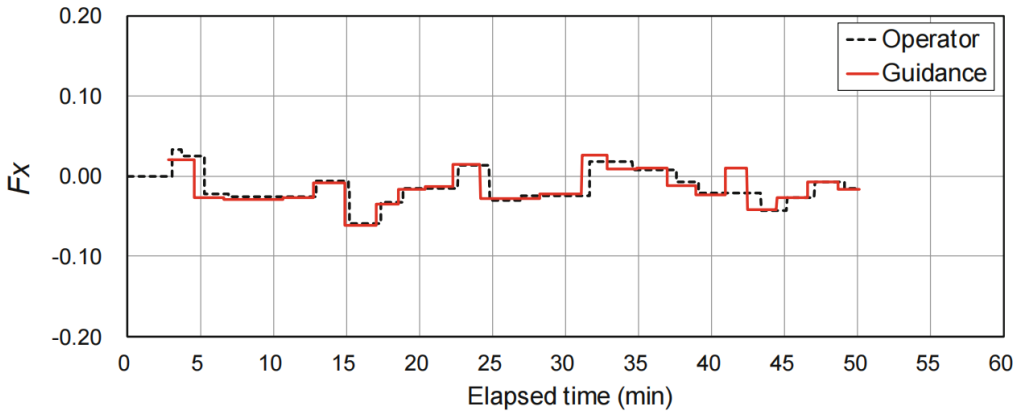

(a) Fx

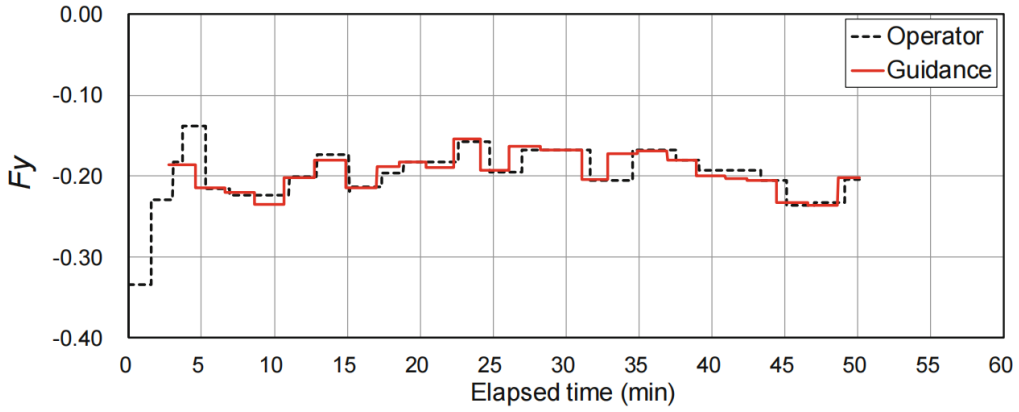

(b) Fy

图 12. 盾构千斤顶合力作用点的时程变化曲线

图13为试验工点控制指标实测值的时程变化曲线，控制指标包括盾构千斤顶行程伸长量的左右差值、盾构机方位角与俯仰角。结果显示，千斤顶行程左右差值与盾构机方位角的实测值，在单环管片掘进完成时均达到了设计值；俯仰角实测值虽未完全达到设计值，但相较于掘进初期已大幅趋近设计目标。

试验结果表明，基于引导系统的指导，可在单环管片的掘进长度内，将所有控制指标维持在设定的容许偏差范围内。其中，盾构机水平方向的控制精度较高，而竖向方向的控制精度略有不足。本次试验的掘进区段为坡度从 0.8% 向 5.0% 过渡的上坡段，推测 Fy 模型未能充分学习到坡度变化的相关规律，是导致竖向控制精度不足的主要原因。此外，引导系统的输出值变动较为频繁，说明引导指令中包含了部分不必要的操作，在盾构千斤顶操作必要性判定的阈值设置方面，仍有较大优化空间。

5 讨论

本研究证实，机器学习模型可在盾构机的方向控制操作中，替代人工完成决策。但要实现引导系统的规模化工程应用，仍面临两大核心挑战。

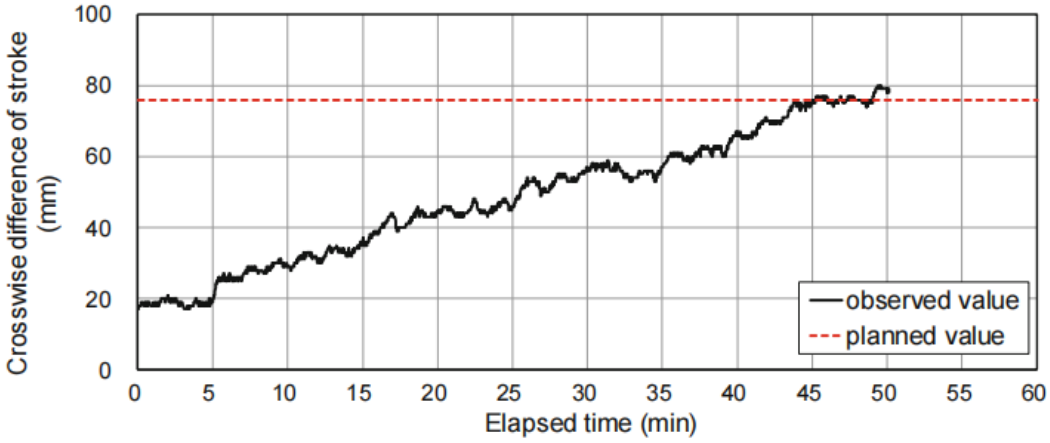

(a) Left–right difference of the extension length of shield jacks' strokes

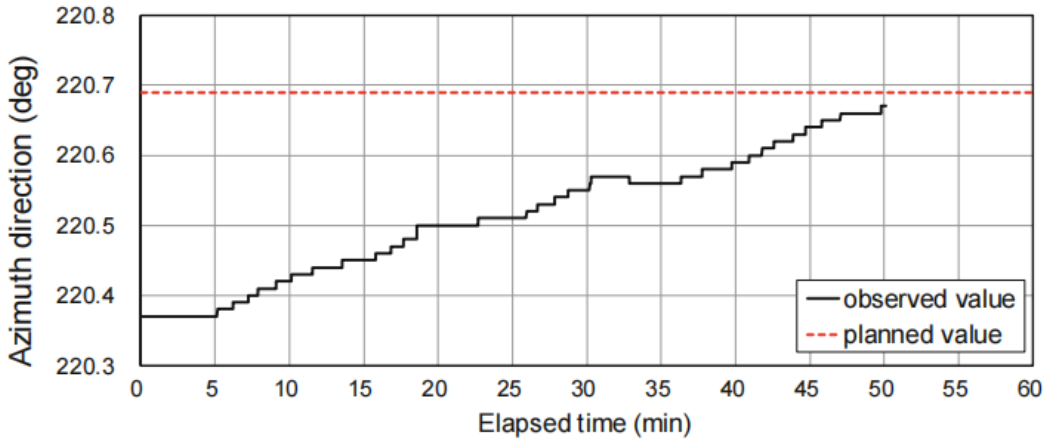

(b) Shield machine's azimuth angle

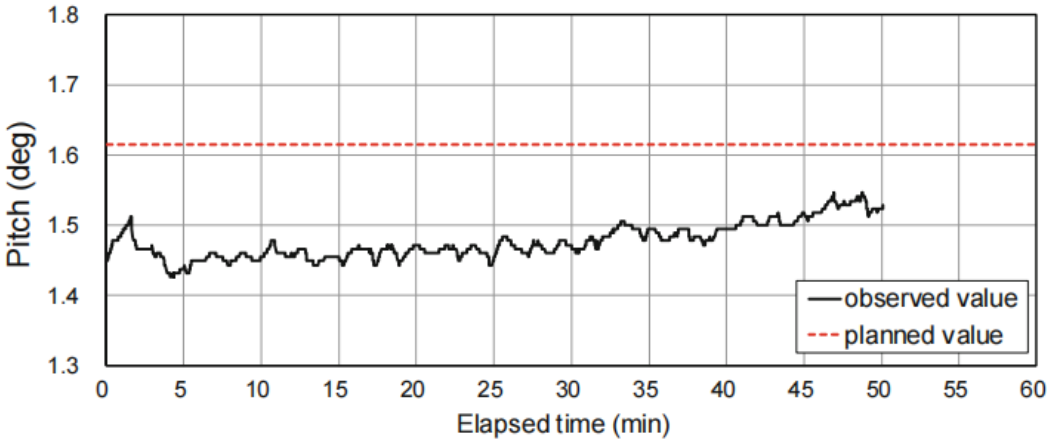

(c) Shield machine's pitch

图 13. 控制指标实测值的时程变化曲线

其一，特征变量的缺失会导致模型预测精度下降。操作人员在控制盾构机时，会同步检查盾尾间隙（衬砌管片与盾构机之间的距离）；当盾尾间隙过小时，为避免衬砌管片破损，通常会采取与设计方案不符的操作。因此，后续研究需将盾尾间隙相关信息，纳入机器学习模型的特征变量中。

其二，目前机器学习模型需针对每个工点单独构建。盾构机的操作方法，与盾构机的设备参数、施工场地的工程条件密切相关；换言之，某一工点确定的目标变量与特征变量之间的映射关系，无法直接应用于其他工点。为实现引导系统的全场景通用，需实现模型训练数据的标准化与泛化。

对于盾构机自动驾驶技术而言，机器学习是一项极具潜力的核心工具。通过采集覆盖盾构隧道各类施工工况的海量数据，可进一步提升机器学习模型的性能。后续研究中，将采用机器学习技术构建除方向控制外的盾构机其他操作预测模型，并将其整合至引导系统中，逐步完善盾构机自动驾驶的全流程技术体系。

6 结论

作为实现盾构机自动驾驶的第一步，本研究基于机器学习技术，研发了一套盾构隧道掘进方向控制引导系统。该系统通过给出盾构千斤顶的标准化操作方案，摆脱了盾构隧道施工质量对操作人员技能水平的依赖，为隧道施工质量提供了稳定保障。通过对机器学习模型与引导系统的系统性能评估，得到以下结论：

1. 机器学习模型的预测值与操作人员的实际操作值具有良好的相关性，二者差异较小。基于盾构机传感器采集的实测数据，可构建出具备熟练操作人员同等技术水平的预测模型。

2. 采用引导系统指导盾构机掘进时，所有控制指标均处于设定的容许偏差范围内，系统未输出任何对隧道施工质量产生不利影响的指令。尽管系统输出中包含部分冗余指令，该问题可通过调整千斤顶操作必要性判定的阈值得到解决。此外，隧道坡度的变化会导致引导系统的性能下降，因此需采用覆盖更多工况的数据集对机器学习模型进行训练。尽管仍存在部分待优化的内容，本研究研发的引导系统已具备实际工程的应用能力。

参考文献

[1] Kuwahara, H., Harada, M., Seno, Y., Takeuchi, M.: Application of fuzzy reasoning to the control of shield tunneling. J.JSCE 391, 169–178 (1988). (in Japanese)

[2] Tateyama, K., Nishitake, S., Kazama, K.: Automatic advancing control of shield machine (in Japanese). J. Rob. Soc. Jpn. 12, 928–932 (1994)

[3] Sugiyama, H., Wada, K., Nakaya, T., Ogi, T.: Preliminary study on shield machine’s operations by using artificial intelligence. In: 2017 JSCE Annual Meeting, vol. 6, pp. 675–676. Japan Society of Civil Engineers, Japan (2017). (in Japanese)

[4] Wada, K., Sugiyama, H., Nozawa, K., Honda, M., Nakaya, T., Ogi, T.: Autonomous direction control of shield machine with AI. In: 2018 JSCE Annual Meeting, vol. 6, pp. 285–286. Japan Society of Civil Engineers, Japan (2018). (in Japanese)

[5] Wada, K., Sugiyama, H., Nozawa, K., Honda, M.: Machine learning model considering the operating characteristics of a shield machine. In: 2019 JSCE Annual Meeting, vol. 6, no. 814. Japan Society of Civil Engineers, Japan (2019). (in Japanese)

[6] Sugiyama, H., Wada, K., Nozawa, K., Honda, M.: Evaluation of the performance of the machine learning model for directional control of a shield machine. In: 2019 JSCE Annual Meeting, vol. 6, no. 813. Japan Society of Civil Engineers, Japan (2019). (in Japanese)

[7] Sugiyama, H., Nozawa, K., Wada, K., Hokari, T.: Development of the support system for the shield machine’s operations. In: 2018 JSCE Annual Meeting, vol. 6, pp. 287–288. Japan Society of Civil Engineers, Japan (2018). (in Japanese)

[8] Shield Tunneling Association of Japan. http://shield-method.gr.jp. Accessed 10 Jan 2020

[9] Jerome, F.: Greedy function approximation: a gradient boosting machine. Ann. Stat. 29(5), 1189–1232 (2001)

[10] Chen, T., Guestrin, C.: XGBoost: a scalable tree boosting system. arXiv, 1603.02754 (2016)